

Introdução à Regressão Linear

Regressão Linear Simples

Fernando Chertman

Objetivos da aula

Ao final, você deverá ser capaz de:

- **Entender** o modelo de regressão linear simples $Y = \beta_0 + \beta_1 X + \varepsilon$.

Objetivos da aula

Ao final, você deverá ser capaz de:

- **Entender** o modelo de regressão linear simples $Y = \beta_0 + \beta_1 X + \varepsilon$.
- **Interpretar** intercepto, inclinação e R^2 .

Objetivos da aula

Ao final, você deverá ser capaz de:

- **Entender** o modelo de regressão linear simples $Y = \beta_0 + \beta_1 X + \varepsilon$.
- **Interpretar** intercepto, inclinação e R^2 .
- **Estimar** os coeficientes por Mínimos Quadrados (MQO) e calcular previsões.

Objetivos da aula

Ao final, você deverá ser capaz de:

- **Entender** o modelo de regressão linear simples $Y = \beta_0 + \beta_1 X + \varepsilon$.
- **Interpretar** intercepto, inclinação e R^2 .
- **Estimar** os coeficientes por Mínimos Quadrados (MQO) e calcular previsões.
- **Reconhecer limitações** (não linearidade, outliers, causalidade $\neq$ correlação).

Motivação

Relações comuns:

- Horas de estudo (X) e nota (Y).

Motivação

Relações comuns:

- Horas de estudo (X) e nota (Y).
- Renda (X) e consumo (Y).

Motivação

Relações comuns:

- Horas de estudo (X) e nota (Y).
- Renda (X) e consumo (Y).
- Temperatura (X) e consumo de energia (Y).

Motivação

Relações comuns:

- Horas de estudo (X) e nota (Y).
- Renda (X) e consumo (Y).
- Temperatura (X) e consumo de energia (Y).

Ideia central: **modelar** como a média de Y varia quando X muda.

Ferramenta: **reta** que melhor aproxima a nuvem de pontos.

Modelo de Regressão Linear Simples

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n$$

- β_0 (intercepto): valor médio de Y quando $X = 0$.

Modelo de Regressão Linear Simples

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n$$

- β_0 (intercepto): valor médio de Y quando $X = 0$.
- β_1 (inclinação): variação média de Y para um aumento unitário em X .

Modelo de Regressão Linear Simples

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n$$

- β_0 (intercepto): valor médio de Y quando $X = 0$.
- β_1 (inclinação): variação média de Y para um aumento unitário em X .
- ε_i : fatores não observados (média zero, variância constante sob suposições clássicas).

Modelo de Regressão Linear Simples

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n$$

- β_0 (intercepto): valor médio de Y quando $X = 0$.
- β_1 (inclinação): variação média de Y para um aumento unitário em X .
- ε_i : fatores não observados (média zero, variância constante sob suposições clássicas).

Objetivo: **estimar** β_0, β_1 a partir da amostra.

Mínimos Quadrados (intuição)

A reta ajustada $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ minimiza a soma dos quadrados dos resíduos:

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2.$$

Mínimos Quadrados (intuição)

A reta ajustada $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ minimiza a soma dos quadrados dos resíduos:

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2.$$

Intuição: penalizar *erros grandes* de forma mais intensa (ao quadrado) para encontrar a melhor reta média.

Mínimos Quadrados (fórmulas fechadas)

Denote $\bar{X} = \frac{1}{n} \sum X_i$ e $\bar{Y} = \frac{1}{n} \sum Y_i$. Então:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)},$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Mínimos Quadrados (fórmulas fechadas)

Denote $\bar{X} = \frac{1}{n} \sum X_i$ e $\bar{Y} = \frac{1}{n} \sum Y_i$. Então:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)},$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Predições: $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$.

Resíduos: $e_i = Y_i - \hat{Y}_i$.

Exemplo prático: dados (estudo $\Rightarrow$ nota)

Vamos usar 10 observações:

X (horas)	1	2	3	4	5	6	7	8	9	10
Y (nota)	7	9	9	14	13	17	18	21	20	25

Médias: $\bar{X} = 5,5$, $\bar{Y} = 15,3$.

Exemplo prático: estimação dos coeficientes

Usando as fórmulas de MQO:

$$\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} \approx 1,9091,$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \approx 4,8000.$$

Exemplo prático: estimação dos coeficientes

Usando as fórmulas de MQO:

$$\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} \approx 1,9091,$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \approx 4,8000.$$

Reta ajustada: $\hat{Y} = 4,8 + 1,9091 X$.

- Interpretação de $\hat{\beta}_1$: cada hora adicional de estudo está associada, em média, a $\approx 1,91$ ponto a mais na nota.

Exemplo prático: estimação dos coeficientes

Usando as fórmulas de MQO:

$$\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} \approx 1,9091,$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \approx 4,8000.$$

Reta ajustada: $\hat{Y} = 4,8 + 1,9091 X$.

- Interpretação de $\hat{\beta}_1$: cada hora adicional de estudo está associada, em média, a $\approx 1,91$ ponto a mais na nota.
- Interpretação de $\hat{\beta}_0$: nota média esperada quando $X = 0$ (nem sempre tem significado substantivo).

Qualidade do ajuste: R^2

Defina:

$$\text{SST} = \sum (Y_i - \bar{Y})^2, \quad \text{SSE} = \sum (Y_i - \hat{Y}_i)^2, \quad R^2 = 1 - \frac{\text{SSE}}{\text{SST}}.$$

Qualidade do ajuste: R^2

Defina:

$$\text{SST} = \sum (Y_i - \bar{Y})^2, \quad \text{SSE} = \sum (Y_i - \hat{Y}_i)^2, \quad R^2 = 1 - \frac{\text{SSE}}{\text{SST}}.$$

Para os dados do exemplo:

$$R^2 \approx 0,957.$$

Leitura: aproximadamente 95,7% da variação de Y é explicada pela variação de X via o modelo linear (no sentido descritivo).

Diagnóstico básico (primeiro contato)

- **Resíduos** sem padrão claro quando plotados contra X .

Diagnóstico básico (primeiro contato)

- **Resíduos** sem padrão claro quando plotados contra X .
- **Outliers** podem distorcer a reta.

Diagnóstico básico (primeiro contato)

- **Resíduos** sem padrão claro quando plotados contra X .
- **Outliers** podem distorcer a reta.
- **Homoscedasticidade** (variância constante dos erros) é desejável.

Diagnóstico básico (primeiro contato)

- **Resíduos** sem padrão claro quando plotados contra X .
- **Outliers** podem distorcer a reta.
- **Homoscedasticidade** (variância constante dos erros) é desejável.
- R^2 alto não implica **causalidade**. Precisamos de desenho causal/experimental, controles, etc.

Limitações e extensões

Limitações:

- Relações *não lineares* (talvez transformar variáveis ou usar modelos não lineares).

Limitações e extensões

Limitações:

- Relações *não lineares* (talvez transformar variáveis ou usar modelos não lineares).
- *Variáveis omitidas* geram viés.

Limitações e extensões

Limitações:

- Relações *não lineares* (talvez transformar variáveis ou usar modelos não lineares).
- *Variáveis omitidas* geram viés.
- *Causalidade* exige suposições/delineamento (não é garantida por regressão simples).

Limitações e extensões

Limitações:

- Relações *não lineares* (talvez transformar variáveis ou usar modelos não lineares).
- *Variáveis omitidas* geram viés.
- *Causalidade* exige suposições/delineamento (não é garantida por regressão simples).

Extensões:

- Regressão **múltipla** ($Y = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k + \varepsilon$).

Limitações e extensões

Limitações:

- Relações *não lineares* (talvez transformar variáveis ou usar modelos não lineares).
- *Variáveis omitidas* geram viés.
- *Causalidade* exige suposições/delineamento (não é garantida por regressão simples).

Extensões:

- Regressão **múltipla** ($Y = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k + \varepsilon$).
- Interações e termos quadráticos (X^2) para capturar curvatura.

Limitações e extensões

Limitações:

- Relações *não lineares* (talvez transformar variáveis ou usar modelos não lineares).
- *Variáveis omitidas* geram viés.
- *Causalidade* exige suposições/delineamento (não é garantida por regressão simples).

Extensões:

- Regressão **múltipla** ($Y = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k + \varepsilon$).
- Interações e termos quadráticos (X^2) para capturar curvatura.
- Ferramentas de inferência (teste t , IC, F) e validação.

Exercícios (conceituais)

E1. Identifique X e Y :

Exercícios (conceituais)

E1. Identifique X e Y :

- 1 Renda e consumo.

Exercícios (conceituais)

E1. Identifique X e Y :

- 1 Renda e consumo.
- 2 Temperatura média diária e vendas de sorvete.

Exercícios (conceituais)

E1. Identifique X e Y :

- ① Renda e consumo.
- ② Temperatura média diária e vendas de sorvete.
- ③ Doses de fertilizante e produtividade agrícola.

Exercícios (conceituais)

E1. Identifique X e Y :

- ① Renda e consumo.
- ② Temperatura média diária e vendas de sorvete.
- ③ Doses de fertilizante e produtividade agrícola.

E2. Interprete $\hat{\beta}_1 < 0$: o que significa?

Exercícios (conceituais)

E1. Identifique X e Y :

- 1 Renda e consumo.
- 2 Temperatura média diária e vendas de sorvete.
- 3 Doses de fertilizante e produtividade agrícola.

E2. Interprete $\hat{\beta}_1 < 0$: o que significa?

E3. Dê um exemplo em que regressão *linear* não seja adequada.

Exercícios (cálculo rápido)

Use os dados do exemplo (10 observações) e:

- 1 Calcule $\bar{X}$, $\bar{Y}$.

Exercícios (cálculo rápido)

Use os dados do exemplo (10 observações) e:

- 1 Calcule $\bar{X}$, $\bar{Y}$.
- 2 Calcule $\hat{\beta}_1$ e $\hat{\beta}_0$ pelas fórmulas.

Exercícios (cálculo rápido)

Use os dados do exemplo (10 observações) e:

- 1 Calcule $\bar{X}$, $\bar{Y}$.
- 2 Calcule $\hat{\beta}_1$ e $\hat{\beta}_0$ pelas fórmulas.
- 3 Obtenha $\hat{Y}_i$ e os resíduos e_i .

Exercícios (cálculo rápido)

Use os dados do exemplo (10 observações) e:

- 1 Calcule $\bar{X}$, $\bar{Y}$.
- 2 Calcule $\hat{\beta}_1$ e $\hat{\beta}_0$ pelas fórmulas.
- 3 Obtenha $\hat{Y}_i$ e os resíduos e_i .
- 4 Calcule R^2 .

Exercícios (cálculo rápido)

Use os dados do exemplo (10 observações) e:

- 1 Calcule $\bar{X}$, $\bar{Y}$.
- 2 Calcule $\hat{\beta}_1$ e $\hat{\beta}_0$ pelas fórmulas.
- 3 Obtenha $\hat{Y}_i$ e os resíduos e_i .
- 4 Calcule R^2 .
- 5 Faça a previsão para $X = 12$: $\hat{Y}(12) = ?$

Encerramento

Resumo:

- Modelo linear simples e interpretação de coeficientes.

Encerramento

Resumo:

- Modelo linear simples e interpretação de coeficientes.
- MQO: ideia de minimização de erros e fórmulas fechadas.

Encerramento

Resumo:

- Modelo linear simples e interpretação de coeficientes.
- MQO: ideia de minimização de erros e fórmulas fechadas.
- Exemplo prático e leitura do R^2 .

Encerramento

Resumo:

- Modelo linear simples e interpretação de coeficientes.
- MQO: ideia de minimização de erros e fórmulas fechadas.
- Exemplo prático e leitura do R^2 .
- Limitações e próximos passos (múltipla, inferência, diagnóstico).

Próxima etapa: regressão múltipla e teste de hipóteses para β_1 .