

Intervalo de Confiança vs. Intervalo de Predição

Intuição, exemplo numérico e aplicação no RStudio

Estatística 2

A ideia central

Em regressão linear, a reta ajustada pode ser usada para responder a duas perguntas diferentes.

Pergunta 1: média esperada

Qual é o valor médio esperado de Y quando $X = x_0$?

Pergunta 2: nova observação individual

Qual será o valor provável de um novo indivíduo com $X = x_0$?

A primeira pergunta leva ao **intervalo de confiança**. A segunda pergunta leva ao **intervalo de predição**.

Modelo de regressão linear simples

Considere o modelo:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

com:

$$E(\varepsilon_i) = 0, \quad \text{Var}(\varepsilon_i) = \sigma^2.$$

A reta estimada é:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i.$$

Para um valor específico x_0 , a previsão pontual é:

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

Intervalo de confiança

O **intervalo de confiança** responde:

“Onde está a média verdadeira de Y para $X = x_0$?”

Ele mede a incerteza sobre a posição da **reta média populacional**.

$$IC_{95\%} : \hat{y}_0 \pm t_{0.025, n-2} SE(\hat{y}_0)$$

onde:

$$SE(\hat{y}_0) = s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

O **intervalo de predição** responde:

“Onde pode cair uma nova observação individual de Y para $X = x_0$?”

Ele inclui duas fontes de incerteza:

- 1 a incerteza sobre a reta estimada;
- 2 a variabilidade individual em torno da reta.

$$IP_{95\%} : \hat{y}_0 \pm t_{0.025, n-2} SE_{pred}$$

$$SE_{pred} = s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

Comparação direta

Os dois intervalos têm o mesmo centro:

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

Mas têm erros-padrão diferentes:

$$SE(IC) = s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

$$SE(IP) = s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

Mensagem principal

O intervalo de predição é mais largo porque inclui a incerteza de um novo erro individual ε .

No gráfico de dispersão com uma reta de regressão:

- A **reta** representa a média esperada de Y dado X .
- O **intervalo de confiança** mostra a incerteza sobre essa média.
- O **intervalo de predição** mostra onde uma nova observação individual pode aparecer.

Frase útil para os alunos

Intervalo de confiança: onde está a reta média.

Intervalo de predição: onde podem estar os pontos individuais.

Exemplo numérico: horas de estudo e nota

Suponha a seguinte amostra:

Horas	1	2	3	4	5	6	7	8	9	10
Nota	52	55	61	66	68	74	78	80	86	90

A regressão estimada é:

$$\widehat{Nota} = 47,80 + 4,218 \cdot Horas.$$

Para $x_0 = 6$ horas:

$$\hat{y}_0 = 47,80 + 4,218 \times 6 = 73,11.$$

Ou seja, a nota prevista para 6 horas de estudo é aproximadamente 73,11.

Exemplo numérico: cálculo dos intervalos

Para essa amostra:

$$n = 10, \quad s = 1,005, \quad t_{0.025,8} = 2,306.$$

Para $x_0 = 6$:

$$SE(IC) = 0,322, \quad SE(IP) = 1,055.$$

Logo:

$$IC_{95\%} = 73,11 \pm 2,306(0,322) = [72,37; 73,85].$$

$$IP_{95\%} = 73,11 \pm 2,306(1,055) = [70,68; 75,54].$$

Interpretação do exemplo

Para alunos com 6 horas de estudo:

Intervalo de confiança

Estamos 95% confiantes de que a **nota média** dos alunos que estudam 6 horas está entre:

72,37 e 73,85.

Intervalo de predição

Para um **novo aluno individual** que estudou 6 horas, a nota prevista está entre:

70,68 e 75,54.

Por que o segundo é maior?

Porque prever um indivíduo é mais incerto do que estimar uma média.

RStudio: ajustando o modelo

No RStudio, primeiro crie a base e ajuste a regressão:

```
dados <- data.frame(  
  horas = c(1,2,3,4,5,6,7,8,9,10),  
  nota  = c(52,55,61,66,68,74,78,80,86,90)  
)  
  
modelo <- lm(nota ~ horas, data = dados)  
  
summary(modelo)
```

O comando `summary(modelo)` mostra os coeficientes estimados, erro-padrão, estatística t , p -valor e R^2 .

Para calcular o intervalo de confiança da média prevista em $horas = 6$:

```
novo <- data.frame(horas = 6)

predict(modelo,
        newdata = novo,
        interval = "confidence",
        level = 0.95)
```

A saída terá três colunas:

- fit: previsão pontual;
- lwr: limite inferior;
- upr: limite superior.

Esse intervalo se refere à **média esperada** de Y quando $X = 6$.

Para calcular o intervalo de predição para uma nova observação com *horas* = 6:

```
predict(modelo,  
        newdata = novo,  
        interval = "prediction",  
        level = 0.95)
```

Esse intervalo se refere a uma **nova observação individual**.

Comparação esperada:

```
# Intervalo de confianca: mais estreito  
# Intervalo de predicao: mais largo
```

RStudio: gráfico com os dois intervalos

```
novo_grid <- data.frame(  
  horas = seq(min(dados$horas), max(dados$horas), length.out = 100)  
)  
  
ic <- predict(modelo, newdata = novo_grid, interval = "confidence")  
ip <- predict(modelo, newdata = novo_grid, interval = "prediction")  
  
plot(dados$horas, dados$nota,  
      xlab = "Horas de estudo", ylab = "Nota",  
      pch = 19)  
  
abline(modelo, lwd = 2)  
  
matlines(novo_grid$horas, ic[, c("lwr", "upr")], lty = 2)  
matlines(novo_grid$horas, ip[, c("lwr", "upr")], lty = 3)  
  
legend("topleft",  
       legend = c("Reta ajustada", "IC 95%", "IP 95%"),  
       lty = c(1, 2, 3), lwd = c(2, 1, 1), bty = "n")
```

Cuidados importantes

- 1 O intervalo de predição não é uma garantia de que qualquer nova observação estará dentro dele.
- 2 A interpretação depende das hipóteses do modelo linear.
- 3 Longe de $\bar{x}$, os dois intervalos ficam mais largos.
- 4 Fora da faixa observada dos dados, a previsão vira extrapolação.

Resumo

O IC estima uma média condicional. O IP prevê uma observação individual.

	Intervalo de Confiança	Intervalo de Predição
Pergunta	Média de Y	Novo valor individual
Centro	$\hat{y}_0$	$\hat{y}_0$
Largura	Menor	Maior
Fonte extra de erro	Não	Sim, erro individual
Uso	Estimar a reta média	Prever novo ponto

Frase final

Intervalo de confiança: incerteza sobre a média.

Intervalo de predição: incerteza sobre uma nova observação.