

Multicolinearidade e Variáveis Dummy na Regressão Linear Múltipla

Estatística 2

10 de abril de 2026

- Conceito e consequências de **multicolinearidade**
- Diagnóstico: correlações, *VIF*
- Estratégias de mitigação
- **Variáveis dummy**: codificação, interpretação, armadilha das dummies
- Interações: mudança de intercepto e inclinação
- Exemplos numéricos e gráficos
- Exercícios e gabarito

O que é multicolinearidade?

Definição: correlação alta entre duas ou mais variáveis explicativas.

O que é multicolinearidade?

Definição: correlação alta entre duas ou mais variáveis explicativas.

Consequências principais:

- Coeficientes instáveis (*alta variância*);
- Erros-padrão inflados $\Rightarrow$ testes t com *baixo poder*;
- Dificuldade de interpretar efeitos parciais.

O que é multicolinearidade?

Definição: correlação alta entre duas ou mais variáveis explicativas.

Consequências principais:

- Coeficientes instáveis (*alta variância*);
- Erros-padrão inflados $\Rightarrow$ testes t com *baixo poder*;
- Dificuldade de interpretar efeitos parciais.

Importante: não induz viés se $E[u | X] = 0$, mas reduz a *precisão*.

fig_multicolinearidade.png

Matriz de correlação entre regressores (sinal de alerta: $|r| > 0,8$).

Matriz de correlação entre regressores (sinal de alerta: $|r| > 0,8$).

Fator de Inflação da Variância (VIF) para X_j :

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

onde R_j^2 vem da regressão X_j contra as demais X_{-j} .

Matriz de correlação entre regressores (sinal de alerta: $|r| > 0,8$).

Fator de Inflação da Variância (VIF) para X_j :

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

onde R_j^2 vem da regressão X_j contra as demais X_{-j} .

Regras de bolso:

- $\text{VIF} > 5$ (*moderado*); $\text{VIF} > 10$ (*severo*).

Exemplo numérico: VIF passo a passo

Suponha duas regressoras padronizadas com $\rho = \text{corr}(X_1, X_2) = 0,9$.

Exemplo numérico: VIF passo a passo

Suponha duas regressoras padronizadas com $\rho = \text{corr}(X_1, X_2) = 0,9$.

Passo 1. Regrida X_1 em X_2 (somente diagnóstico). Com dados padronizados, $R_1^2 \approx \rho^2 = 0,9^2 = 0,81$.

Exemplo numérico: VIF passo a passo

Suponha duas regressoras padronizadas com $\rho = \text{corr}(X_1, X_2) = 0,9$.

Passo 1. Regrida X_1 em X_2 (somente diagnóstico). Com dados padronizados, $R_1^2 \approx \rho^2 = 0,9^2 = 0,81$.

Passo 2. Calcule o VIF:

$$\text{VIF}_1 = \frac{1}{1 - R_1^2} = \frac{1}{1 - 0,81} = \frac{1}{0,19} \approx 5,26.$$

Exemplo numérico: VIF passo a passo

Suponha duas regressoras padronizadas com $\rho = \text{corr}(X_1, X_2) = 0,9$.

Passo 1. Regrida X_1 em X_2 (somente diagnóstico). Com dados padronizados, $R_1^2 \approx \rho^2 = 0,9^2 = 0,81$.

Passo 2. Calcule o VIF:

$$\text{VIF}_1 = \frac{1}{1 - R_1^2} = \frac{1}{1 - 0,81} = \frac{1}{0,19} \approx 5,26.$$

Conclusão: há *multicolinearidade relevante* (VIF acima de 5). Isso tende a inflar $SE(\hat{\beta}_1)$ e reduzir o poder dos testes.

- Remover/combinar regressores redundantes (com base teórica);
- Transformações (diferenças, razões), *feature engineering*;
- Coletar mais dados em regiões pouco observadas de X ;
- Métodos de *shrinkage* (Ridge/Lasso) — fora do escopo de MQO clássico;
- PCA/Análise Fatorial quando o objetivo é previsão/estrutura latente.

Exemplo simples:

$$Y_i = \beta_0 + \beta_1 D_i + u_i, \quad D_i = \begin{cases} 1 & \text{se pertence ao grupo 1} \\ 0 & \text{se pertence ao grupo base} \end{cases}$$

Exemplo simples:

$$Y_i = \beta_0 + \beta_1 D_i + u_i, \quad D_i = \begin{cases} 1 & \text{se pertence ao grupo 1} \\ 0 & \text{se pertence ao grupo base} \end{cases}$$

Interpretação:

- $\beta_0 = \mathbb{E}[Y \mid D = 0]$ (média do grupo base);
- $\beta_1 = \mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]$ (diferença de médias).

Interações com dummy (mudança de inclinação)

$$Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 (X \times D) + u.$$

- Grupo base ($D = 0$): $Y = \beta_0 + \beta_1 X$;
- Grupo 1 ($D = 1$): $Y = (\beta_0 + \beta_2) + (\beta_1 + \beta_3)X$.

Interações com dummy (mudança de inclinação)

$$Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 (X \times D) + u.$$

- Grupo base ($D = 0$): $Y = \beta_0 + \beta_1 X$;
- Grupo 1 ($D = 1$): $Y = (\beta_0 + \beta_2) + (\beta_1 + \beta_3)X$.

Teste de igualdade de inclinações: $H_0 : \beta_3 = 0$.

Exemplo numérico (dummy simples)

Considere $Y_i = \beta_0 + \beta_1 D_i + u_i$ e amostras de tamanho iguais nos dois grupos. As médias amostrais são $\bar{Y}_0$ e $\bar{Y}_1$. Então:

$$\hat{\beta}_0 = \bar{Y}_0, \quad \hat{\beta}_1 = \bar{Y}_1 - \bar{Y}_0.$$

Exemplo numérico (dummy simples)

Considere $Y_i = \beta_0 + \beta_1 D_i + u_i$ e amostras de tamanho iguais nos dois grupos. As médias amostrais são $\bar{Y}_0$ e $\bar{Y}_1$. Então:

$$\hat{\beta}_0 = \bar{Y}_0, \quad \hat{\beta}_1 = \bar{Y}_1 - \bar{Y}_0.$$

Interpretação: $\hat{\beta}_1$ é a *diferença de médias*. O teste t para $\beta_1 = 0$ é equivalente ao teste t de duas amostras (sob variâncias iguais no MQO clássico).

Exercícios (para discutir em sala)

1. **(Multicolinearidade)** Em $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$, suponha $\text{corr}(X_1, X_2) = 0,92$.
- (a) Calcule o VIF de X_1 usando $R_1^2 \approx 0,92^2$.
 - (b) Explique o efeito no $SE(\hat{\beta}_1)$.

Exercícios (para discutir em sala)

1. **(Multicolinearidade)** Em $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$, suponha $\text{corr}(X_1, X_2) = 0,92$.
 - (a) Calcule o VIF de X_1 usando $R_1^2 \approx 0,92^2$.
 - (b) Explique o efeito no $SE(\hat{\beta}_1)$.
2. **(Armadilha das dummies)** Uma variável categórica tem 4 categorias.
 - (a) Quantas dummies usar com intercepto?
 - (b) O que acontece se incluir as 4?

Exercícios (para discutir em sala)

1. **(Multicolinearidade)** Em $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$, suponha $\text{corr}(X_1, X_2) = 0,92$.
 - (a) Calcule o VIF de X_1 usando $R_1^2 \approx 0,92^2$.
 - (b) Explique o efeito no $SE(\hat{\beta}_1)$.
2. **(Armadilha das dummies)** Uma variável categórica tem 4 categorias.
 - (a) Quantas dummies usar com intercepto?
 - (b) O que acontece se incluir as 4?
3. **(Dummy simples)** Em $Y = \beta_0 + \beta_1 D + u$, você obteve $\bar{Y}_0 = 12,4$ e $\bar{Y}_1 = 15,1$.
 - (a) Estime $\hat{\beta}_0$ e $\hat{\beta}_1$.
 - (b) Interprete $\hat{\beta}_1$.

Exercícios (para discutir em sala)

- (Multicolinearidade)** Em $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$, suponha $\text{corr}(X_1, X_2) = 0,92$.
 - Calcule o VIF de X_1 usando $R_1^2 \approx 0,92^2$.
 - Explique o efeito no $SE(\hat{\beta}_1)$.
- (Armadilha das dummies)** Uma variável categórica tem 4 categorias.
 - Quantas dummies usar com intercepto?
 - O que acontece se incluir as 4?
- (Dummy simples)** Em $Y = \beta_0 + \beta_1 D + u$, você obteve $\bar{Y}_0 = 12,4$ e $\bar{Y}_1 = 15,1$.
 - Estime $\hat{\beta}_0$ e $\hat{\beta}_1$.
 - Interprete $\hat{\beta}_1$.
- (Interação)** No modelo $Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 XD + u$,
 - escreva a reta para $D=0$ e para $D=1$;
 - como testar se as inclinações são iguais?

- (a) $R_1^2 \approx 0,92^2 = 0,8464 \Rightarrow VIF_1 \approx 1/(1-0,8464) \approx 6,51$.

(b) VIF alto $\Rightarrow SE(\hat{\beta}_1)$ inflado, testes t com baixo poder.
- (a) Usar $k-1 = 3$ dummies com intercepto.

(b) Incluir as 4 gera *multicolinearidade perfeita* porque $D_1 + D_2 + D_3 + D_4 = 1$.
- (a) $\hat{\beta}_0 = \bar{Y}_0 = 12,4$; $\hat{\beta}_1 = \bar{Y}_1 - \bar{Y}_0 = 2,7$.

(b) O grupo $D=1$ tem média 2,7 unidades maior que o grupo base.
- (a) $D=0$: $Y = \beta_0 + \beta_1 X$; $D=1$: $Y = \beta_0 + \beta_2 + (\beta_1 + \beta_3)X$.

(b) Teste $H_0 : \beta_3 = 0$ (teste t usual).

- VIF traduz “o quanto” a variância de $\hat{\beta}_j$ incha por colinearidade.
- Evite a armadilha das dummies: para k categorias, use $k-1$ dummies com intercepto.
- Interação ($X \times \text{dummy}$) permite inclinação distinta por grupo; teste β_3 .

Matriz de correlação (exemplo numérico)

Dados simulados (5 observações):

Obs	X_1	X_2
1	-1.20	-1.13
2	-0.50	-0.33
3	+0.20	+0.20
4	+0.80	+0.53
5	+1.10	+0.88

	X_1	X_2
X_1	1.000	0.992
X_2	0.992	1.000

Tabela: Matriz de correlação (exemplo didático). $r = \text{corr}(X_1, X_2) = 0.992$, $R^2 = r^2 = 0.984$, $\text{VIF} = 1/(1 - R^2) = 62.40$.

Em R (diagnóstico de X_1):

```
x1 <- c(-1.20, -0.50, +0.20, +0.80, +1.10)
x2 <- c(-1.13, -0.33, +0.20, +0.53, +0.88)
summary(lm(x1 ~ x2)) #  $R^2 \approx 0.984$ 
VIF1 <- 1/(1 - 0.984) #  $\approx 62.40$ 
```

No Excel (supondo X_1 em B2:B6 e X_2 em C2:C6):

- Obtenha R^2 com =RSQ(B2:B6, C2:C6) $\Rightarrow 0.984$.
- Calcule o VIF: =1/(1 - RSQ(B2:B6, C2:C6)) $\Rightarrow 62.40$.

Interpretação: correlação alta ($|r|$ grande) $\Rightarrow R^2$ alto na regressão auxiliar $\Rightarrow$ VIF elevado.