

Intervalo de Confiança vs. Intervalo de Predição (Regressão Linear Simples)

Cenário: Regressão Linear Simples

Consideramos o modelo

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad i = 1, \dots, n,$$

onde $E[u_i | X_i] = 0$ e $Var(u_i | X_i) = \sigma^2$.

Usamos a amostra para estimar b_0 e b_1 (Mínimos Quadrados Ordinários).

Nosso objetivo: comparar o **Intervalo de Confiança (IC)** para parâmetros/para a média condicional com o **Intervalo de Predição** para uma nova observação.

1. Intervalo de Confiança (IC) para os parâmetros

Ideia: quantificar a incerteza sobre os parâmetros populacionais (β_0, β_1) .

Ex.: IC de 95% para β_1 :

$$b_1 \pm t_{n-2, 0.975} \cdot SE(b_1).$$

$SE(b_1)$ é o erro-padrão do estimador de β_1 .

Interpretação: em 95% das amostras (sob as suposições), o intervalo conteria o valor verdadeiro β_1 .

2. Intervalo de Predição (para Y em $X = x_0$)

Objetivo: prever uma nova observação individual Y_0 quando $X = x_0$.

Previsão pontual:

$$\hat{y}_0 = b_0 + b_1 x_0.$$

Intervalo de predição de 95%:

$$\hat{y}_0 \pm t_{n-2, 0.975} \cdot s \cdot \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}},$$

onde s é o erro-padrão da regressão (estimativa de σ).

3. Diferença Intuitiva

- **IC para parâmetros** (β_0, β_1) : localiza onde provavelmente está o valor verdadeiro dos coeficientes na população.
- **IC para a média** $E[Y | X = x_0]$: localiza o valor esperado de Y para o x_0 dado.
- **Intervalo de predição**: localiza a nova observação individual Y_0 para x_0 .

⇒ O **intervalo de predição** é sempre mais largo que o **IC para a média**: ele inclui a variância extra do erro idiossincrático (+1 dentro da raiz).

4. Exemplo rápido (notas $\times$ horas)

- IC de 95% para β_1 : “cada hora extra aumenta a nota entre 0,8 e 1,2 pontos”.
- IC para a média quando $X = 10$: “a média prevista para 10h está entre 80 e 85”.
- Predição para um indivíduo quando $X = 10$: “um aluno que estuda 10h terá nota entre 60 e 105”.

Leitura: a média condicional tem menor variabilidade; já a observação individual inclui a dispersão do erro u .

(Opcional) Fórmulas úteis

- Erro-padrão da regressão:

$$s = \sqrt{\frac{\sum e_i^2}{n-2}}.$$

- Soma de quadrados em X :

$$S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2.$$

- Erros-padrão dos parâmetros:

$$SE(b_1) = \frac{s}{\sqrt{S_{xx}}}, \quad SE(b_0) = s \sqrt{\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}}}.$$

- IC para a média em x_0 :

$$\hat{y}(x_0) \pm t_{n-2, 0.975} \cdot s \cdot \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}}.$$

Resumo

- IC para parâmetros mede incerteza sobre (β_0, β_1) .
- IC para a média (em x_0) mede incerteza sobre $E[Y | X = x_0]$.
- Intervalo de predição mede incerteza sobre uma nova Y_0 em x_0 .
- Predição $\Rightarrow$ intervalos maiores (inclui variância do erro individual).