

Suposições do modelo de RLS e Inferência

Estatística II

Regressão: Por que um modelo estatístico?

- Em ciências sociais e econômicas, raramente um fenômeno é uma relação matemática exata de outro (determinismo).
- Outros fatores podem afetar a variável de interesse, gerando variações observadas em y .
- A influência combinada desses fatores implica uma distribuição para a média dos valores de y dado x .
- Modelo amostral: $y = b_0 + b_1x + e$.

Regressão: Por que um modelo estatístico?

- Em ciências sociais e econômicas, raramente um fenômeno é uma relação matemática exata de outro (determinismo).
- Outros fatores podem afetar a variável de interesse, gerando variações observadas em y .
- A influência combinada desses fatores implica uma distribuição para a média dos valores de y dado x .
- Modelo amostral: $y = b_0 + b_1x + e$.

Regressão: Por que um modelo estatístico?

- Em ciências sociais e econômicas, raramente um fenômeno é uma relação matemática exata de outro (determinismo).
- Outros fatores podem afetar a variável de interesse, gerando variações observadas em y .
- A influência combinada desses fatores implica uma distribuição para a média dos valores de y dado x .
- Modelo amostral: $y = b_0 + b_1x + e$.

Regressão: Por que um modelo estatístico?

- Em ciências sociais e econômicas, raramente um fenômeno é uma relação matemática exata de outro (determinismo).
- Outros fatores podem afetar a variável de interesse, gerando variações observadas em y .
- A influência combinada desses fatores implica uma distribuição para a média dos valores de y dado x .
- Modelo amostral: $y = b_0 + b_1x + e$.

- Para prever uma variável por meio de outra, raramente temos a população inteira.
- Usamos amostragem para estimar parâmetros e o termo de erro da população.
- Modelo populacional: $y = \beta_0 + \beta_1 x + \varepsilon$.
- b_0 e b_1 são estimadores *não viesados* de β_0 e β_1 .
- O resíduo e é um estimador do termo de erro ε .

Inferência

- Para prever uma variável por meio de outra, raramente temos a população inteira.
- Usamos amostragem para estimar parâmetros e o termo de erro da população.
- Modelo populacional: $y = \beta_0 + \beta_1 x + \varepsilon$.
- b_0 e b_1 são estimadores *não viesados* de β_0 e β_1 .
- O resíduo e é um estimador do termo de erro ε .

Inferência

- Para prever uma variável por meio de outra, raramente temos a população inteira.
- Usamos amostragem para estimar parâmetros e o termo de erro da população.
- Modelo populacional: $y = \beta_0 + \beta_1 x + \varepsilon$.
- b_0 e b_1 são estimadores *não viesados* de β_0 e β_1 .
- O resíduo e é um estimador do termo de erro ε .

Inferência

- Para prever uma variável por meio de outra, raramente temos a população inteira.
- Usamos amostragem para estimar parâmetros e o termo de erro da população.
- Modelo populacional: $y = \beta_0 + \beta_1 x + \varepsilon$.
- b_0 e b_1 são estimadores *não viesados* de β_0 e β_1 .
- O resíduo e é um estimador do termo de erro ε .

- Para prever uma variável por meio de outra, raramente temos a população inteira.
- Usamos amostragem para estimar parâmetros e o termo de erro da população.
- Modelo populacional: $y = \beta_0 + \beta_1 x + \varepsilon$.
- b_0 e b_1 são estimadores *não viesados* de β_0 e β_1 .
- O resíduo e é um estimador do termo de erro ε .

Suposições do modelo (RLS)

$$y = \beta_0 + \beta_1 x + \varepsilon$$

- $\mathbb{E}[\varepsilon] = 0$.
- Variância constante de ε para todos os x (homocedasticidade).
- Independência entre os valores de ε (sem autocorrelação).
- Normalidade: ε é normalmente distribuído.

Suposições do modelo (RLS)

$$y = \beta_0 + \beta_1 x + \varepsilon$$

- $\mathbb{E}[\varepsilon] = 0$.
- Variância constante de ε para todos os x (homocedasticidade).
- Independência entre os valores de ε (sem autocorrelação).
- Normalidade: ε é normalmente distribuído.

Suposições do modelo (RLS)

$$y = \beta_0 + \beta_1 x + \varepsilon$$

- $\mathbb{E}[\varepsilon] = 0$.
- Variância constante de ε para todos os x (homocedasticidade).
- Independência entre os valores de ε (sem autocorrelação).
- Normalidade: ε é normalmente distribuído.

Suposições do modelo (RLS)

$$y = \beta_0 + \beta_1 x + \varepsilon$$

- $\mathbb{E}[\varepsilon] = 0$.
- Variância constante de ε para todos os x (homocedasticidade).
- Independência entre os valores de ε (sem autocorrelação).
- Normalidade: ε é normalmente distribuído.

Resíduos

- A distribuição dos resíduos fornece a melhor informação sobre a distribuição do termo de erro.
- Resíduo (e_i): diferença entre o valor observado e o previsto pela regressão.
- Erro-padrão da estimativa (S_e); calcula-se com $(n - 2)$ graus de liberdade (estimamos b_0 e b_1).
- Padronização dos resíduos permite uso da Normal.
- **Outliers**: observações com resíduo padronizado $|z_i| > 3$ devem ser investigadas.

Resíduos

- A distribuição dos resíduos fornece a melhor informação sobre a distribuição do termo de erro.
- Resíduo (e_i): diferença entre o valor observado e o previsto pela regressão.
- Erro-padrão da estimativa (S_e); calcula-se com $(n - 2)$ graus de liberdade (estimamos b_0 e b_1).
- Padronização dos resíduos permite uso da Normal.
- **Outliers**: observações com resíduo padronizado $|z_i| > 3$ devem ser investigadas.

Resíduos

- A distribuição dos resíduos fornece a melhor informação sobre a distribuição do termo de erro.
- Resíduo (e_i): diferença entre o valor observado e o previsto pela regressão.
- Erro-padrão da estimativa (S_e); calcula-se com $(n - 2)$ graus de liberdade (estimamos b_0 e b_1).
- Padronização dos resíduos permite uso da Normal.
- **Outliers**: observações com resíduo padronizado $|z_i| > 3$ devem ser investigadas.

Resíduos

- A distribuição dos resíduos fornece a melhor informação sobre a distribuição do termo de erro.
- Resíduo (e_i): diferença entre o valor observado e o previsto pela regressão.
- Erro-padrão da estimativa (S_e); calcula-se com $(n - 2)$ graus de liberdade (estimamos b_0 e b_1).
- Padronização dos resíduos permite uso da Normal.
- **Outliers**: observações com resíduo padronizado $|z_i| > 3$ devem ser investigadas.

Resíduos

- A distribuição dos resíduos fornece a melhor informação sobre a distribuição do termo de erro.
- Resíduo (e_i): diferença entre o valor observado e o previsto pela regressão.
- Erro-padrão da estimativa (S_e); calcula-se com $(n - 2)$ graus de liberdade (estimamos b_0 e b_1).
- Padronização dos resíduos permite uso da Normal.
- **Outliers**: observações com resíduo padronizado $|z_i| > 3$ devem ser investigadas.

Tratamento de outliers e diagnóstico

- Outliers podem *viesar* b_0 e b_1 . Opções:
 - ▶ Eliminação;
 - ▶ Substituição (média/limite);
 - ▶ Transformações (ln, raiz, $1/x$, etc.).
- Análise gráfica dos resíduos é essencial; há também testes específicos.

Tratamento de outliers e diagnóstico

- Outliers podem *viesar* b_0 e b_1 . Opções:
 - ▶ Eliminação;
 - ▶ Substituição (média/limite);
 - ▶ Transformações (ln, raiz, $1/x$, etc.).
- Análise gráfica dos resíduos é essencial; há também testes específicos.

Tratamento de outliers e diagnóstico

- Outliers podem *viesar* b_0 e b_1 . Opções:
 - ▶ Eliminação;
 - ▶ Substituição (média/limite);
 - ▶ Transformações (ln, raiz, $1/x$, etc.).
- Análise gráfica dos resíduos é essencial; há também testes específicos.


Tratamento de outliers e diagnóstico

- Outliers podem *viesar* b_0 e b_1 . Opções:
 - ▶ Eliminação;
 - ▶ Substituição (média/limite);
 - ▶ Transformações (ln, raiz, $1/x$, etc.).
- Análise gráfica dos resíduos é essencial; há também testes específicos.

Gráficos de resíduos – variância


Heterocedasticidade

Resíduos com variância não constante (heterocedasticidade)




Homocedasticidade

Resíduos com variância constante (homocedasticidade)




Gráficos de resíduos – normalidade e independência

Não normal




Normal



Erros não independentes



Erros independentes



Testes para suposições

- Quando os gráficos não são conclusivos, use testes formais.
- **Heterocedasticidade:**
 - ▶ H_0 : erros são homocedásticos; H_a : heterocedásticos.
- **Normalidade:**
 - ▶ H_0 : erros seguem distribuição Normal; H_a : não Normal.

Testes para suposições

- Quando os gráficos não são conclusivos, use testes formais.
- **Heterocedasticidade:**
 - ▶ H_0 : erros são homocedásticos; H_a : heterocedásticos.
- Normalidade:
 - ▶ H_0 : erros seguem distribuição Normal; H_a : não Normal.

Testes para suposições

- Quando os gráficos não são conclusivos, use testes formais.
- **Heterocedasticidade:**
 - ▶ H_0 : erros são homocedásticos; H_a : heterocedásticos.
- **Normalidade:**
 - ▶ H_0 : erros seguem distribuição Normal; H_a : não Normal.

Teste da significância (relação linear)

- Objetivo: testar se a suposição de relação linear na população é plausível em nível α .
- Há relação se $\beta_1 \neq 0$; estimamos com b_1 .
- Dois testes equivalentes em RLS simples: **t** e **F** (levam à mesma conclusão).

Teste da significância (relação linear)

- Objetivo: testar se a suposição de relação linear na população é plausível em nível α .
- Há relação se $\beta_1 \neq 0$; estimamos com b_1 .
- Dois testes equivalentes em RLS simples: **t** e **F** (levam à mesma conclusão).

Teste da significância (relação linear)

- Objetivo: testar se a suposição de relação linear na população é plausível em nível α .
- Há relação se $\beta_1 \neq 0$; estimamos com b_1 .
- Dois testes equivalentes em RLS simples: **t** e **F** (levam à mesma conclusão).

Pelo teste t

Equação populacional: $E(y) = \beta_0 + \beta_1 x$

Hipóteses:

- $H_0 : \beta_1 = 0$ vs $H_a : \beta_1 \neq 0$

Estatística de teste:

- $t = \frac{b_1}{S_{b_1}}$ com $(n-2)$ g.l. (se as suposições valem)
- Rejeite H_0 se $|t| > t_{\text{crítico}}$, ou se $p\text{-valor} < \alpha$, ou se o IC de β_1 não contém 0.

Teste F e relação com χ^2

- O teste F pode ser visto como uma razão de duas variáveis qui-quadrado independentes, divididas pelos seus g.l.:

$$F = \frac{\chi_1^2/\nu_1}{\chi_2^2/\nu_2}, \quad F \sim F(\nu_1, \nu_2).$$

- Em regressão:
 - ▶ Numerador: soma de quadrados da regressão (SQ_{Reg}) qui-quadrado com k g.l.
 - ▶ Denominador: soma de quadrados dos resíduos (SQ_{Res}) qui-quadrado com $(n - k - 1)$ g.l.
- Portanto, o teste F compara variabilidade explicada e não explicada, ambos derivados de distribuições χ^2 .
- Caso $k = 1$: $F = t^2$ e $t^2 \sim \chi_1^2$, reforçando a conexão.

Comparativo entre t , F e χ^2

	Teste t	Teste F	Teste χ^2
Hipótese	$\beta_j = 0$	$\beta_1 = \dots = \beta_k = 0$	$\sigma^2 = \sigma_0^2$ ou ajuste de modelo
Distribuição	t_{n-k-1}	$F(k, n-k-1)$	$\chi_{g.l.}^2$
Origem	Razão normal/ raiz qui-quadrado	Razão de dois $\chi^2/g.l.$	Soma de quadrados normalizados
Relação	$t^2 \sim F(1, n-k-1)$	$F \sim \frac{(\chi^2/k)}{(\chi^2/(n-k-1))}$	Caso especial de soma de normais $N(0, 1)^2$

Exemplos numéricos dos testes

- Teste t : em uma regressão simples com $n = 25$, obtemos $b_1 = 2.5$ e erro-padrão 1.0.

$$t = 2.5/1.0 = 2.5, \quad g.l. = 23.$$

Valor crítico (5% bicaudal) $t_{0.025,23} \approx 2.07 \Rightarrow$ rejeitamos H_0 .

- Teste F : em regressão múltipla ($k = 3$, $n = 30$), $SQ_{Reg} = 120$, $SQ_{Res} = 60$.

$$F = (120/3)/(60/26) = 40/2.31 \approx 17.3.$$

Valor crítico $F_{3,26;0.05} \approx 2.98 \Rightarrow$ rejeitamos H_0 .

- Teste χ^2 : para variância amostral $s^2 = 4.5$, $n = 20$, variância hipotética $\sigma_0^2 = 3$.

$$\chi^2 = (19 \cdot 4.5)/3 = 28.5.$$

Valor crítico superior $\chi_{19;0.95}^2 \approx 30.1 \Rightarrow$ não rejeitamos H_0 .

- Rejeitar H_0 **não** implica:
 - ▶ Causalidade (apenas associação!).
 - ▶ Linearidade para todos os possíveis valores de x .
 - ▶ Significância prática (tamanho de efeito relevante).
- Verifique sempre os pressupostos do termo de erro; violações podem invalidar coeficientes e conclusões.

- Rejeitar H_0 **não** implica:
 - ▶ Causalidade (apenas associação!).
 - ▶ Linearidade para todos os possíveis valores de x .
 - ▶ Significância prática (tamanho de efeito relevante).
- Verifique sempre os pressupostos do termo de erro; violações podem invalidar coeficientes e conclusões.

- Rejeitar H_0 **não** implica:
 - ▶ Causalidade (apenas associação!).
 - ▶ Linearidade para todos os possíveis valores de x .
 - ▶ Significância prática (tamanho de efeito relevante).
- Verifique sempre os pressupostos do termo de erro; violações podem invalidar coeficientes e conclusões.

IC para $E(y_p)$ em um x_p

- Fatores que alargam/restringem o intervalo:
 - ▶ Nível de confiança;
 - ▶ Dispersão dos dados;
 - ▶ Tamanho da amostra;
 - ▶ Distância de x_p à média amostral de x .

Observação

Os ICs e IPs serão construídos no RStudio. Não é necessário memorizar fórmulas.

IC para $E(y_p)$ em um x_p

- Fatores que alargam/restringem o intervalo:
 - ▶ Nível de confiança;
 - ▶ Dispersão dos dados;
 - ▶ Tamanho da amostra;
 - ▶ Distância de x_p à média amostral de x .

Observação

Os ICs e IPs serão construídos no RStudio. Não é necessário memorizar fórmulas.

IC para $E(y_p)$ em um x_p

- Fatores que alargam/restringem o intervalo:
 - ▶ Nível de confiança;
 - ▶ Dispersão dos dados;
 - ▶ Tamanho da amostra;
 - ▶ Distância de x_p à média amostral de x .

Observação

Os ICs e IPs serão construídos no RStudio. Não é necessário memorizar fórmulas.

IC para $E(y_p)$ em um x_p

- Fatores que alargam/restringem o intervalo:
 - ▶ Nível de confiança;
 - ▶ Dispersão dos dados;
 - ▶ Tamanho da amostra;
 - ▶ Distância de x_p à média amostral de x .

Observação

Os ICs e IPs serão construídos no RStudio. Não é necessário memorizar fórmulas.

Intervalo de predição para y_p em x_p

- Os mesmos fatores que afetam o IC afetam também o IP.

Observação

Construiremos no RStudio. Não é necessário memorizar fórmulas.

Cuidados ao fazer previsão

- Bons ajustes (suposições, R^2 , significância) **não** bastam.
- Atenção a:
 - ▶ Pontos influentes;
 - ▶ Extrapolação;
 - ▶ Causalidade.

Cuidados ao fazer previsão

- Bons ajustes (suposições, R^2 , significância) **não** bastam.
- Atenção a:
 - ▶ Pontos influentes;
 - ▶ Extrapolação;
 - ▶ Causalidade.

Cuidados ao fazer previsão


- Bons ajustes (suposições, R^2 , significância) **não** bastam.
- Atenção a:
 - ▶ Pontos influentes;
 - ▶ Extrapolação;
 - ▶ Causalidade.

Cuidados ao fazer previsão

- Bons ajustes (suposições, R^2 , significância) **não** bastam.
- Atenção a:
 - ▶ Pontos influentes;
 - ▶ Extrapolação;
 - ▶ Causalidade.


Pontos influentes

- A inclusão de um ponto extremo pode alterar substancialmente a inclinação da reta estimada.



Extrapolação

- A relação linear vale para a região dos dados amostrados; fora dela, a previsão pode ser enganosa.



- **Modelo RLS: suposições sobre ε e papel dos resíduos.**
- Diagnóstico: gráficos e testes formais (heterocedasticidade, normalidade).
- Significância da relação linear: testes t e F (RLS).
- IC e IP: fatores que afetam a largura; construção no RStudio.
- Previsão: cuidado com pontos influentes, extrapolação e causalidade.

- Modelo RLS: suposições sobre ε e papel dos resíduos.
- Diagnóstico: gráficos e testes formais (heterocedasticidade, normalidade).
- Significância da relação linear: testes t e F (RLS).
- IC e IP: fatores que afetam a largura; construção no RStudio.
- Previsão: cuidado com pontos influentes, extrapolação e causalidade.

Resumo

- Modelo RLS: suposições sobre ε e papel dos resíduos.
- Diagnóstico: gráficos e testes formais (heterocedasticidade, normalidade).
- Significância da relação linear: testes t e F (RLS).
- IC e IP: fatores que afetam a largura; construção no RStudio.
- Previsão: cuidado com pontos influentes, extrapolação e causalidade.

Resumo

- Modelo RLS: suposições sobre ε e papel dos resíduos.
- Diagnóstico: gráficos e testes formais (heterocedasticidade, normalidade).
- Significância da relação linear: testes t e F (RLS).
- IC e IP: fatores que afetam a largura; construção no RStudio.
- Previsão: cuidado com pontos influentes, extrapolação e causalidade.

- Modelo RLS: suposições sobre ε e papel dos resíduos.
- Diagnóstico: gráficos e testes formais (heterocedasticidade, normalidade).
- Significância da relação linear: testes t e F (RLS).
- IC e IP: fatores que afetam a largura; construção no RStudio.
- Previsão: cuidado com pontos influentes, extrapolação e causalidade.