

0. SETUP (1ª CÉLULA)

```
import pandas as pd
postos = pd.read_csv("postos_sp_2025.csv", sep=";",
decimal=",")
distrib = pd.read_csv("distribuicao_municipios_sp_2025.csv",
sep=";", decimal=",")

# Strip espaço fantasma em todas colunas de texto
for col in postos.select_dtypes(include="object").columns:
    postos[col] = postos[col].str.strip()

postos["Mes"] = (postos["Data da Coleta"].str[6:10] + "-"
+ postos["Data da Coleta"].str[3:5])
print(postos.shape, distrib.shape; postos.head())
```

CSV BR: sempre sep=";" + decimal=",". Sem isso, parse quebra ou número vira string.

MODELO MENTAL (LÊ ANTES DE TUDO)

DataFrame é a tabela inteira (2D, várias colunas e linhas). **Series** é uma coluna sozinha (1D). Quando tu pega `df["c"]`, recebe Series. Quando pega `df[["c1","c2"]]` (lista), recebe DataFrame. Series tem métodos de coluna (`mean`, `str.upper`, `value_counts`); DataFrame tem operações sobre múltiplas colunas.

Filtro de linha sempre tem 2 etapas mentais, mesmo numa linha só. Primeiro, cria uma Series booleana com a condição (`df["c"] == "X"` retorna `True/False` por linha). Segundo, aplica essa Series dentro do `df[...]`. O pandas vê uma Series booleana ali dentro e entende: "fica só com as linhas `True`". Não dá pra "filtrar com string", só com booleana.

Atualizar coluna vs destruir DataFrame. `df["c"] = ALGO` atualiza a coluna `c`, mantém o resto do DataFrame intacto (esquerda é coluna). `df = ALGO` sobrescreve o DataFrame inteiro (esquerda é variável). Se tu fizer `df = df["c"].str.lower()`, o `df` vira uma Series e as outras colunas somem.

Por que existe `.str`. Métodos de string Python (`upper`, `replace`, `contains`) funcionam em uma string só. Coluna do pandas é Series com centenas de strings. `.str` é a ponte: aplica o método em cada string da coluna, retorna Series nova. Sem `.str`, dá erro porque Series não tem `upper`, `replace`, etc.

groupby = split, apply, combine. `df.groupby("c")["v"].mean()` divide o `df` em pedaços por valor de `c`, calcula a média de `v` em cada pedaço, junta tudo numa Series com `c` no índice. Equivalente direto da tabela dinâmica do Excel.

merge = PROCV de tabela inteira. Junta dois DataFrames por uma chave em comum (coluna que existe nos dois). `how="inner"` só mantém chaves presentes nos dois lados (descarta o que sobra), mas **ADICIONA** todas as colunas do segundo DataFrame que enriquecem as linhas. Se a chave real precisa de várias colunas, passa lista (`on=["k1","k2","k3"]`), senão vira produto cartesiano e explode.

Método tem (), atributo não. `df.shape`, `df.columns`, `df.dtypes` são atributos (sem parêntese). `df.head()`, `df.mean()`, `df["c"].str.upper()` são métodos (com parêntese). Esquecer `()` não dá erro, retorna o objeto-método em vez do valor (saída do tipo `<bound method>`).

Como ler um traceback. Erro vermelho gigante: ignora as 20 linhas do meio. A última linha diz o que houve (`KeyError`, `TypeError`, etc) e qual valor causou. A primeira linha do traceback diz qual célula tua causou. Dois pedaços, ignora o resto.

1. INSPEÇÃO

<code>df.head(n)</code>	<code>tail()</code>	<code>sample()</code>	linhas
<code>df.shape</code>	<code>(sem ())</code>		(lin, col)
<code>df.info()</code>	<code>dtypes</code>	<code>columns</code>	tipos/nomes
<code>df.describe()</code>			num: count/mean/std/min/Q/max
<code>describe(include="all")</code>			+ texto
<code>len(df)</code>			nº linhas

2. SELEÇÃO DE COLUMNA

```
df["c"]          # Series (1D)
df[["c1","c2"]]  # DataFrame (várias, ordem da lista)
df[["c"]]        # DataFrame com 1 col (≠ Series)
```

1 colchete vira Series, 2 colchetes viram DataFrame. Pra reordenar colunas, usa 2.

3. FILTRO LÓGICO (LINHA)

```
cond = df["Produto"] == "GASOLINA"  # Series booleana
df[cond]                             # filtra

df[df["Produto"] == "GASOLINA"]
df[df["Valor de Venda"] > 6]
df[df["Bandeira"] != "BRANCA"]
df[df["Bandeira"].isin(["VIBRA","RAIZEN"])]
len(df[df["Produto"]=="GASOLINA"])  # quantas
```

Ops: `==` `!=` `>` `<` `>=` `<=` e `.isin([...])`.

4. AND / OR / NOT

```
# NUNCA and/or/not. Sempre & | ~
df[(df["Produto"]=="GASOLINA") & (df["Valor de Venda"]>6)]
df[(df["Bandeira"]=="VIBRA") | (df["Bandeira"]=="RAIZEN")]
df[~(df["Bandeira"]=="BRANCA")]
```

```
# Recomendado (cada cond como variável):
c1 = df["Produto"]=="GASOLINA"
c2 = df["Valor de Venda"]>6
df[c1 & c2]
```

Cada condição entre parênteses. Esquecer é erro #1.

5. LOC / ILOC

```
df.loc[cond, "Valor de Venda"]
df.loc[cond, ["Revenda","Valor de Venda"]]
df.loc[df["Produto"]=="GASOLINA","Valor de Venda"].mean()
df.iloc[0]          # 1ª linha (posição)
df.iloc[0:5, 0:3]   # FIM EXCLUSIVO
df.loc[5:10]        # FIM INCLUSIVO
```

	loc	iloc
Usa	rótulo	posição
Fim	inclusivo	exclusivo

6. .STR (STRINGS NA COLUMNA)

```
df["c"].str.upper() / .lower() / .title() / .strip()
df["c"].str.len()          # tamanho
df["c"].str.contains("POST0") # booleana (filtro!)
df["c"].str.startswith("AUTO") / .endswith("LTDA")
df["c"].str.replace("LTDA","") # SUBSTRING
df["c"].str[0] .str[-3:] .str[6:10] # slice
df["c"].str.split()          # vira lista
df["c"].str.split(expand=True) # vira DF
df["c"].str.split().str[-1]   # último elemento
```

```
df["c"].str.upper().str.replace("LTDA","").str.strip() #
encadeia
```

Sem `.str`: 'Series' object has no 'upper'. Sempre `.str` antes.

7. REPLACE VS .STR.REPLACE

Forma	Compara
<code>col.replace("SP","BA")</code>	valor inteiro
<code>col.str.replace("SP","BA")</code>	substring no texto

```
df["Estado"] = df["Estado"].replace("SP","Sao Paulo")
df["Bandeira"] =
df["Bandeira"].replace({"BRANCA":"SEM","VIBRA":"BR"})
```

8. CRIAR / ATUALIZAR COLUMNA

```
df["nova"] = df["a"] + df["b"] # cria à direita
df["a"] = df["a"] * 1.1        # substitui
df["Pais"] = "Brasil"          # constante
df["Cid_U"] = df["Município"].str.upper()
```

Pegadinha mortal: `df = df["c"].str.lower()` DESTRÓI o DF (vira Series). Esquerda tem que ser `df["c"]`, NUNCA `df`.

9. ASTYPE (CONVERTER TIPO)

```
df["c"] = df["c"].astype(float / str / int)
```

```
# Se Valor veio string (decimal não pegou):
df["Valor de Venda"] = (df["Valor de Venda"]
.str.replace(",",".").astype(float))
```

String + número falha. Converte: `"C" + df["id"].astype(str)`.

10. ESTATÍSTICA NUMÉRICA

```
df["c"].mean() .median() .std() .var()
df["c"].min() .max() .sum() .count() # count = não-
nulos
df["c"].quantile(0.25) .quantile(0.75)
df["c"].describe() # tudo de uma vez
df["c"].idxmax() # ÍNDICE do maior
```

Sem `()`: `df["c"].mean` retorna *bound method*, não o número.

17. CASO REAL: POSTOS + DISTRIB (MARGEM)

1. Cria Mes em postos (formato YYYY-MM):
postos["Mes"] = (postos["Data da Coleta"].str[6:10] + "-"
+ postos["Data da Coleta"].str[3:5])

2. Junta pela chave TRIPLA (sem isso, cartesiano):
juntos = pd.merge(postos, distrib,
on=["Municipio","Produto","Mes"], how="inner")

3. Margem (revenda – atacado):
juntos["margem"] = juntos["Valor de Venda"] –
juntos["Preco_Distribuicao"]

4. Margem média por bandeira (ranking):
juntos.groupby("Bandeira")
["margem"].mean().sort_values(ascending=False)

18. CENÁRIOS TÍPICOS (COLE ADAPTANDO)

Postos distintos em SP capital
df[df["Municipio"]=="SAO PAULO"]["CNPJ"].nunique()
Top 5 cidades gasolina mais cara
(df[df["Produto"]=="GASOLINA"]
.groupby("Municipio")["Valor de Venda"].mean()
.sort_values(ascending=False).head(5))
Bandeira mais freq. em SP
df[df["Municipio"]=="SAO PAULO"]
["Bandeira"].value_counts().head(1)
Município com diesel mais caro (nome)
(df[df["Produto"]=="DIESEL S10"]
.groupby("Municipio")["Valor de Venda"].mean().idxmax())
Preço médio mês a mês de gasolina em SP
sp = df[(df["Produto"]=="GASOLINA")
& (df["Municipio"]=="SAO PAULO")].copy()
sp["Mes"] = sp["Data da Coleta"].str[6:10]+"-"+sp["Data da
Coleta"].str[3:5]
sp.groupby("Mes")["Valor de Venda"].mean()
Revenda contém "AUTO POSTO" E bandeira VIBRA
c1 = df["Revenda"].str.contains("AUTO POSTO")
c2 = df["Bandeira"]=="VIBRA"
df[c1 & c2]
Municípios com gasolina máxima > 7
g = df[df["Produto"]=="GASOLINA"]
m = g.groupby("Municipio")["Valor de Venda"].max()
m[m > 7]
Distribuição por produto (1 linha)
df.groupby("Produto")["Valor de Venda"].describe()
Qtd bandeiras por cidade (top 10)
df.groupby("Municipio")
["Bandeira"].nunique().sort_values(ascending=False).head(10)
Mês mais caro pra gasolina
g = df[df["Produto"]=="GASOLINA"].copy()
g["Mes"] = g["Data da Coleta"].str[6:10]+"-"+g["Data da
Coleta"].str[3:5]
g.groupby("Mes")["Valor de Venda"].mean().idxmax()
Margem média por município (top 10)
juntos.groupby("Municipio")
["margem"].mean().sort_values(ascending=False).head(10)
2 resultados na mesma célula
display(df["a"].mean())
display(df["b"].mean())

19. ERROS TÍPICOS → CAUSA

Erro	Causa
KeyError: 'X'	nome de coluna errado, OU df virou Series
FileNotFoundError	caminho relativo errado, usa absoluto
ParserError: expected N, saw M	faltou sep=";"
'Series' has no 'upper'	esqueceu .str
'method' object does not support item assignment	usou [em vez de (
'float' object does not support item assignment	a = b = expr em cadeia
TypeError em aritmética	coluna é string, usa astype(float)
SettingWithCopyWarning	filtrou sem .copy()
DF gigante após merge	chave incompleta no on
Output <bound method>	esqueceu () ao chamar função
Coluna numérica vira object	faltou decimal=","

Dica do prof: erro vermelho, lê a última linha do traceback. É onde o pandas diz o problema.

20. REGRAS-MÃE (DECORA ESTAS)

- = atribui, == compara. Erro é clássico.
- Estatística sempre em coluna: df["c"].mean(), não df.mean().
- Atualizar coluna: esquerda é df["c"], nunca só df.
- Booleano: & | ~, cada cond entre parênteses.
- loc fim inclusivo, iloc fim exclusivo.
- Métodos com (); atributos sem (shape, columns, dtypes).
- sort_values não persiste sozinho. Reatribui.
- Sempre .str antes de função de string.
- copy() ao criar subset que vai ser modificado.
- Chave de merge incompleta → cartesiano. Confere shape depois.
- Kernel restart zera tudo. Roda tudo em ordem (Restart and Run All).
- Salva com Cmd+S a cada exercício.

21. FLUXO DOS 100 MIN (LEPI, SEM INTERNET)

1. 1–5': lê TODAS as perguntas. Classifica mental: filtro? groupby? merge?
2. 5–10': setup, confere shape e head. Se Valor virou string, converte com astype.
3. 10–50': faz as fáceis primeiro (value_counts, mean, filtro). Trava pontos.
4. 50–80': combinadas (filtro+groupby, merge, encadeamento).
5. 80–85': Restart and Run All pra confirmar consistência. Confere nomes completos dos 3 do grupo no notebook.
6. 85–100': eClass abre nos últimos 15 min. Representante sobe .ipynb + preenche questionário com as respostas. Sem internet antes.