

Aula 10:

Data Science e Analytics: Definições, Técnicas Analíticas e Ferramentas

Disciplina: Tecnologia, Dados e Negócios

Suely Fischer Omura
suely.omura@fgv.br



Data Science e Analytics

"Uma empresa possui milhões de registros de clientes. Isso significa que ela toma melhores decisões?"

- **Não.** Ter dados não significa gerar conhecimento. O valor surge quando os dados são transformados em insights


"Como transformar dados em decisões inteligentes?"



- **Dados → Informação → Conhecimento → Decisão → Valor!**

Data Science e Analytics

- ♣ **Data Science** é uma disciplina interdisciplinar que combina estatística, ciência da computação, inteligência artificial e conhecimento de negócios que utiliza métodos, processos, algoritmos e sistemas científicos para extrair conhecimento e gerar valor a partir dos dados (Sharda et al., 2024)
 - **Projeto de Data Science (fases):** Problema de negócio → coleta dos dados → preparação dos dados → treinamento do modelo → avaliação → implantação → monitoramento
- ♣ **Analytics** é o uso extensivo de dados, métodos quantitativos, modelos estatísticos, inteligência artificial e modelos preditivos para apoiar a tomada de decisão (Sharda et al., 2024)






Data Science e Analytics

DATA SCIENCE vs. ANALYTICS

Do dado ao valor: duas abordagens complementares para gerar insights e apoiar decisões

ETAPAS DE DATA SCIENCE



VS.

ETAPAS DE ANALYTICS



EXEMPLO PRÁTICO – DATA SCIENCE

Problema: Prever churn de clientes em um e-commerce.

Aplicação das etapas:



★ Resultado: Modelo prevê clientes com alto risco de churn e gera insights acionáveis.

EXEMPLO PRÁTICO – ANALYTICS

Problema: Queda nas vendas de uma loja física.

Aplicação das etapas:



★ Resultado: Ações recomendadas para recuperar vendas e otimizar campanhas.

Data Science e Analytics

♣ Onde Data Science e Analytics se encaixam? E a IA?

Business Intelligence (BI)

Monitorar e reportar.
O que aconteceu ou o que está acontecendo?

Analytics

Explicar e prever.
Por que isso ocorreu e o que provavelmente acontecerá?

Data Science (DS)

Construir modelos inteligentes.
Qual é a melhor solução? Como melhorá-la continuamente?

Artificial Intelligence (AI)

Apoiar e automatizar decisões.
Como agir em tempo real? Como apoiar ou automatizar parte da decisão?



- ♣ *BI, Analytics e DS* não são disciplinas independentes, mas sim partes de uma evolução da capacidade analítica das organizações
- Muitas ferramentas são utilizadas tanto em *Analytics* quanto em DS. A diferença está na finalidade e na profundidade de uso, e não apenas na ferramenta em si



Data Science e Analytics

BI, ANALYTICS E DATA SCIENCE: UMA PERSPECTIVA GERENCIAL

Capacidades complementares que evoluem da informação à inteligência para gerar valor no negócio



Data Science e Analytics: Analogia Prática

Business Intelligence (informa):

O médico possui uma visão clara da condição atual do paciente, baseada em indicadores e exames básicos



Analytics (explica e prevê):

O médico compreende as causas do problema e antecipa possíveis cenários futuros



Data Science (aprende e recomenda):

São construídos modelos inteligentes capazes de aprender, identificar padrões complexos e apoiar decisões médicas



Artificial Intelligence (executa e apóia decisões):

A IA amplia a capacidade do médico, reduz o tempo de resposta e melhora a precisão das decisões, mas a responsabilidade clínica continua sendo do profissional de saúde





Data Science e Analytics: Técnicas

- **Analytics** é organizado em torno de **perguntas de negócio**. Utiliza Estatística + Visualização + Modelagem quantitativa para explicar e apoiar decisões. Voltado ao profissional de negócio
- **Data Science** é organizado pelo **método técnico**. Utiliza Estatística + Computação + Machine Learning + IA para resolver problemas complexos e desenvolver modelos inteligentes. Voltado ao cientista de dados / programador)
- As duas áreas compartilham diversas técnicas, mas **diferem** principalmente **pelo nível de sofisticação, pela escala dos dados e pelo objetivo do projeto**

<i>Business Analytics</i>	<i>Data Science</i>
Estatística Descritiva	<i>Machine Learning</i>
Regressão, Testes Estatísticos	<i>Deep Learning</i>
Séries Temporais	NLP (<i>Natural Language Processing</i>)
Correlação	Visão Computacional
Árvores de Decisão	IA Generativa (LLMs e modelos multimodais)
Clusterização	Aprendizado por Reforço
Regras de Associação	<i>Feature Engineering</i> (Engenharia de Atributos)
Otimização	Pipelines automatizados de <i>ML</i> (AutoML)



Data Science e Analytics: Ferramentas

- *Analytics* e *Data Science* não são separados por ferramentas, mas pela natureza do problema de negócio e pela sofisticação analítica (Sharda et al., 2024)
 - Um profissional pode utilizar Python para fazer uma simples regressão (*Analytics*) ou para treinar uma rede neural profunda (*Data Science*)
 - Da mesma forma, Power BI pode servir apenas para monitorar KPIs ou incorporar modelos preditivos desenvolvidos em Python
- O uso mais típico em *Analytics* tem foco descritivo/diagnóstico, voltado ao usuário de negócio, enquanto em *Data Science* o foco é preditivo/prescritivo, voltado ao cientista/engenheiro de dados

<i>Analytics</i>	<i>Data Science</i>
Excel	Python
Power BI	R
Tableau	Jupyter Notebook
SQL	Scikit-learn
SPSS	TensorFlow
SAS	PyTorch
Alteryx	Spark
Stata	Databricks





Data Science e Analytics

♣ Limitações de *Analytics e Data Science*

- **Qualidade dos dados:** dados incompletos, desatualizados ou mal coletados comprometem qualquer análise, por mais sofisticada que seja a técnica
- **Confusão entre correlação e causalidade:** um dos erros mais comuns na interpretação de resultados — um padrão pode existir sem que haja relação causal real
- **Viés nos dados e nos modelos:** dados históricos podem reproduzir desigualdades ou distorções (ex.: viés de gênero, raça, região), que os modelos replicam e amplificam
- **Dependência de contexto:** um modelo ou métrica que funciona bem em uma empresa/setor pode não se aplicar a outro contexto, época ou público
- **Foco no que é fácil de medir, não no que importa:** métricas fáceis de coletar às vezes substituem os indicadores realmente relevantes para o negócio
- **Questões éticas e regulatórias:** privacidade, uso de dados pessoais e conformidade com legislações (como a LGPD) impõem restrições ao que pode ser coletado e analisado
- **Cultura organizacional e maturidade analítica:** sem lideranças engajadas e cultura orientada a dados, os insights não se traduzem em decisões efetivas

Leitura Complementar

Davenport, T. H., & Harris, J. G. (2017). *Competing on analytics: Updated, with a new introduction*. Harvard Business Review Press.

Sharda, R., Delen, D., & Turban, E. (2024). *Business intelligence, analytics, data science, and AI (12th ed.)*. Pearson.

Provost, F., & Fawcett, T. (2013). *Data science for business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media.