

Aula 10: *Data Science e Analytics: Definições, Técnicas Analíticas, Ferramentas e Limitações*

Disciplina: Tecnologia, Dados e Negócios

Suely Fischer Omura
suely.omura@fgv.br





Feedback Estudo de Caso FC Barcelona

1. Nível de maturidade analítica (BDAC) do FC Barcelona:

Dimensão	Nível BDAC	Evidências
Infraestrutura tecnológica	Médio (saindo do baixo)	Integração parcial, ainda com legado de silos
Qualidade e governança de dados	Média (políticas em implantação)	Data Manager e data warehouse criados, mas dados manuais, atrasados e sem dono claro
Capital humano	Média inicial (equipe analítica em crescimento)	Poucos especialistas, contratações planejadas
Cultura organizacional	Média (uso misto de experiência e dados)	Intenção clara de decidir com dados, mas silos e lógica de "temporada"
Uso estratégico de dados	Média (no esporte, baixa no restante)	Predominam dashboards descritivos; preditivo só no esporte

Conclusão:

O Barça saiu de um nível baixo, com sistemas isolados, decisões baseadas na intuição e até mesmo sem um plano estratégico antes de 2015. **Hoje está em um nível médio, com estruturas formais já estabelecidas, mas ainda sem consolidação.** Para chegar ao nível alto, precisa de dados confiáveis e atuais, de competências analíticas difundidas e de *analytics* integrado às decisões estratégicas fora do campo



Feedback Estudo de Caso FC Barcelona

2. Sugestões de governança e gestão de dados para:

Problemas do FC Barcelona	Sugestões de Governança e Gestão de Dados
Silos e ausência de papéis e responsabilidade clara sobre os dados	• Formalizar os papéis de cada domínio de dados (sócios, instalações, negócios, corporativo, esporte, torcedor digital). Data Owner (definir as regras de uso), Data Steward (garantir a qualidade) e Data Custodian (equipe de TI que garante o acesso e infraestrutura técnica). • Criar um Comitê de Governança de Dados para priorizar iniciativas de dados e resolver conflitos entre áreas. • Dar ao comitê um plano visual de longo prazo plurianual, independente dos ciclos de temporada e dos ciclos eleitorais.
KPIs indefinidos e falta de significado comum dos dados	• Criar um glossário de negócios e um catálogo de metadados. Cada KPI teria definição, fórmula, fonte, dono, frequência de atualização e regra de negócio documentados. • Racionalizar os 110 dashboards em um conjunto menor de KPIs oficiais, aprovados pelo comitê. • Adotar métricas de governança, como o percentual de dados automatizados, o índice de qualidade por domínio, o tempo de atualização e o uso efetivo dos dashboards.



Feedback Estudo de Caso FC Barcelona

2. Sugestões de governança e gestão de dados para:

Problemas do FC Barcelona	Sugestões de Governança e Gestão de Dados
Dependência de dados controlados por terceiros	• Criar uma política corporativa de compartilhamento de dados, com cláusulas-padrão obrigatórias em todo contrato de franquia, licença, patrocínio ou terceirização. Essas cláusulas definiriam quais dados entregar, em que formato, com que frequência (SLA) e via API. • Para os grandes parceiros, usar o peso da marca Barça na negociação de patrocínios e direitos. • Incluir a dependência de plataformas externas, como a das redes sociais, no mapa de riscos de dados. Em paralelo, criar canais próprios (app, site, Wi-Fi do estádio inteligente) para capturar dados de forma direta.
Baixa qualidade, coleta manual e dados desatualizados	• Priorizar a automação da coleta na origem, com pipelines ETL/ELT (processo para extração de dados brutos) e APIs ligadas ao data warehouse, aproveitando a consolidação no NEXUS (fornecedor). • Criar regras de validação automáticas, cobrindo completude, consistência, formato e duplicidade, com alertas para os Data Stewards. • Onde o lançamento manual for inevitável, como nos dados médicos, usar formulários digitais padronizados. • Definir uma política de ciclo de vida, com regras de captura, retenção, arquivamento e descarte para cada tipo de dado.



Feedback Estudo de Caso FC Barcelona

2. Sugestões de governança e gestão de dados para:

Problemas do FC Barcelona	Sugestões de Governança e Gestão de Dados
Visão fragmentada do torcedor e riscos de privacidade	• Implantar MDM* do torcedor/cliente, com identificador único (ID Barça) que consolide CRM, sócios, bilheteria, loja física, e-commerce, museu, app e Wi-Fi em uma versão única e oficial do torcedor. • Aplicar privacidade desde a concepção (privacy by design): gestão de consentimento, classificação dos dados por sensibilidade, controle de acesso por perfil e anonimização para as análises de IA. • Fazer auditorias periódicas de conformidade com o GDPR, conduzidas pelo comitê e pela área de compliance.
Capital humano com limitações em literacia de dados e destreza tecnológica	• Criar um programa de letramento em dados para gestores e um processo para reter internamente o conhecimento gerado nas parcerias com universidades, com documentação, transferência de modelos e cláusulas de propriedade intelectual. • Profissionais capacitados e treinamento contínuo poderiam fortalecer a agilidade e eficiência do clube, além de diminuir a burocracia e resistência.

* MDM (master data management) é uma disciplina de TI e negócios focada em **unificar e organizar** os dados mais críticos de uma organização — como cadastros de clientes, produtos e fornecedores — **em uma única fonte confiável**.

Atualização

Aula Passada:

1. *Big Techs* (Negócios e Diferencial Competitivo)
2. *Big Data* (Governança, Gestão e Arquitetura de Dados; Desafios)

Hoje:

1. *Data Science e Analytics*
2. Definições, Técnicas Analíticas, Ferramentas e Limitações




Data Science e Analytics

"Uma empresa possui milhões de registros de clientes. Isso significa que ela toma melhores decisões?"

- **Não.** Ter dados não significa gerar conhecimento. O valor surge quando os dados são transformados em *insights* e apoiam decisões
- **Dados → Informação → Conhecimento → Decisão → Valor!**

"Como transformar dados em decisões inteligentes?"






Data Science vs. Analytics

Se são duas abordagens complementares para **gerar insights e apoiar decisões**, como podemos diferenciá-las?

- **Ciclo de Data Science:** descreve a sequência de passos do processo seguido para responder às perguntas
- **Níveis de Analytics:** classificam o tipo de pergunta que se responde



Vídeo: <https://www.youtube.com/watch?v=QoEpC7jUb9k>



Ciclo de *Data Science*

1. Problema (definir o problema de negócio, os objetivos e as métricas de sucesso)



Reduzir o *churn* de clientes em 15% em 12 meses, medido pela taxa de cancelamento mensal

2. Dados (coletar dados de fontes internas e externas relevantes)



CRM, interações no site, histórico de compras, chamados ao SAC, dados demográficos

3. Preparo (limpar, tratar erros, transformar e integrar os dados)



Tratar valores nulos, padronizar formatos de dados, remover duplicidades, unir bases por ID

4. Análise (explorar os dados para entender padrões, relações e anomalias)



Identificar segmentos de clientes com maior *churn*; verificar se muitos chamados ao SAC antecedem o cancelamento

5. Modelagem (criar variáveis, *feature engineering*, treinar e avaliar modelos para fazer previsões)



Criar frequência de uso e tempo desde o último contato; treinar um modelo de ML para prever *churn* e avaliá-lo com *recall* e AUC

6. Visualização/Comunicação (comunicar *insights* de forma clara e acionável para *stakeholders*)



Dashboard com risco de *churn* por segmento e principais drivers, com recomendação de ação (oferta de retenção para clientes de alto risco)

Etapas são sequenciais na lógica, mas o processo é cíclico



Níveis de *Analytics*

Análise Descritiva (o que aconteceu?)

Resume dados históricos para entender o que ocorreu em um período



Saber quantas vendas foram feitas no último trimestre ou qual foi o tráfego de um site

Análise Diagnóstica (por que aconteceu?)

Analisa as causas e fatores que levaram ao resultado de um evento



Descobrir que as vendas caíram em um mês específico porque um novo concorrente abriu na mesma região

Análise Preditiva (o que vai acontecer?)

Usa padrões de dados históricos, estatísticas e ML (aprendizado de máquina) para estimar tendências ou eventos futuros



Prever picos de sazonalidade nas compras de fim de ano ou detectar possíveis fraudes em transações financeiras

Análise Prescritiva (o que deve ser feito?)

Fornece recomendações concretas e planos de ação baseados nos resultados previstos, utilizando IA para otimizar decisões



Definir automaticamente o preço ideal de um produto ou sugerir a melhor rota de entrega para reduzir custos

Os níveis de *Analytics* dependem da pergunta de negócio, e não de uma sequência obrigatória



Onde BI, IA, *Analytics* e *Data Science* se sobrepõem?

Conjuntos de práticas e técnicas (atuam sobre esses níveis)	O que ocorreu?	Por que ocorreu?	O que vai ocorrer?	O que deve ser feito?
	Descritivo	Diagnóstico	Preditivo	Prescritivo
	BI Núcleo (dashboards, relatórios)	Forte (drill-down)	Fraco, mas crescente	Raro
	Data science Presente (análise exploratória)	Presente (estatística, causas)	Núcleo (modelos de ML)	Parcial (otimização, recomendação)
	IA Pontual (NLP, clustering)	Pontual (detecção de anomalias)	Forte (machine learning)	Forte (decisão e ação automatizadas)
Níveis de <i>Analytics</i> (classificam o tipo de pergunta que se responde)				

Visão em camadas:

- Os níveis de *Analytics* classificam o tipo de pergunta; o BI atua sobretudo no descritivo e diagnóstico, a ciência de dados concentra-se no preditivo avançando ao prescritivo, e a IA fornece as técnicas (como machine learning) que se sobrepõem à ciência de dados no preditivo e ao prescritivo.



Caso: reduzir o *churn* de clientes em 15%. Cada nível a analisa por um ângulo distinto

	Descritivo	Diagnóstico	Preditivo	Prescritivo
Pergunta	O que ocorreu?	Por que ocorreu?	O que ocorrerá?	O que fazer?
Problema	Taxa de cancelamento por mês e por plano	Por que o plano básico cancela mais?	Probabilidade de cada cliente cancelar em 90 dias	Qual oferta de retenção oferecer a cada cliente?
Técnicas	Estatística descritiva (média, mediana, desvio), agregações, análise exploratória, séries históricas, segmentação	Correlação, testes de hipótese, cohort analysis, análise de causa raiz, árvores de decisão para explicar fatores	Regressão logística, random forest (ML), gradient boosting (ML), redes neurais, séries temporais	Otimização, simulação, testes A/B, inferência causal, aprendizado por reforço
Ferramentas	Power BI, Tableau, Looker, Qlik, Excel, SQL	Power BI e Tableau (drill-down), SQL, Python (scipy, statsmodels), R	Python (scikit-learn, XGBoost, TensorFlow, PyTorch), R, Jupyter, AutoML (H2O, Vertex AI, SageMaker), MLflow	Python (OR-Tools, PuLP, DoWhy), Gurobi, CPLEX, plataformas de experimentação (Optimizely), sistemas de recomendação
Entrega	Dashboard e relatórios	Análise explicativa	Modelo com probabilidade por cliente	Recomendação ou decisão automatizada




Data Science e Analytics: Técnicas

- ***Analytics*** é organizado em torno de **perguntas de negócio** e é voltado ao profissional de negócio
- ***Data Science*** é organizado pelo **método técnico** é voltado ao cientista de dados ou programador
- As duas áreas compartilham diversas técnicas, mas **diferem** principalmente **pelo nível de sofisticação, pela escala dos dados e pelo objetivo do projeto**

Analytics	Data Science
Estatística Descritiva	Machine Learning
Regressão, Testes Estatísticos	Deep Learning
Séries Temporais	NLP (Natural Language Processing)
Correlação	Visão Computacional
Árvores de Decisão	IA Generativa (LLMs e modelos multimodais)
Clusterização	Aprendizado por Reforço
Regras de Associação	Feature Engineering (Engenharia de Atributos)
Otimização	Pipelines automatizados de ML (AutoML)

Data Science e Analytics: Ferramentas

- **Analytics e Data Science** não são separados por ferramentas, mas pela natureza do problema de negócio e pela sofisticação analítica (Sharda et al., 2024)
 - Um profissional pode utilizar Python para fazer uma simples regressão (*Analytics*) ou para treinar uma rede neural profunda (*Data Science*)
 - Da mesma forma, Power BI pode servir apenas para monitorar KPIs ou incorporar modelos preditivos desenvolvidos em Python



Analytics	Data Science
Excel	Python
Power BI	R
Tableau	Jupyter Notebook
SQL	Scikit-learn
SPSS	TensorFlow
SAS	PyTorch
Alteryx	Spark
Stata	Databricks



Data Science e Analytics

♣ Limitações de *Analytics e Data Science*

- **Qualidade dos dados:** dados incompletos, desatualizados ou mal coletados comprometem qualquer análise, por mais sofisticada que seja a técnica
- **Confusão entre correlação e causalidade:** um dos erros mais comuns na interpretação de resultados — um padrão pode existir sem que haja relação causal real
- **Viés nos dados e nos modelos:** dados históricos podem reproduzir desigualdades ou distorções (ex.: viés de gênero, raça, região), que os modelos replicam e amplificam
- **Dependência de contexto:** um modelo ou métrica que funciona bem em uma empresa/setor pode não se aplicar a outro contexto, época ou público
- **Foco no que é fácil de medir, não no que importa:** métricas fáceis de coletar às vezes substituem os indicadores realmente relevantes para o negócio
- **Questões éticas e regulatórias:** privacidade, uso de dados pessoais e conformidade com legislações (como a LGPD) impõem restrições ao que pode ser coletado e analisado
- **Cultura organizacional e maturidade analítica:** sem lideranças engajadas e cultura orientada a dados, os insights não se traduzem em decisões efetivas



Trabalho Final

- O trabalho final (relatório escrito) é composto por 4 blocos:

1. Sumário Executivo

- Principais pontos e conclusões do relatório, somente em uma página.

2. Caracterização da Empresa Pesquisada

- Descrição breve e apresentação de dados do negócio: segmento de atuação, porte, faturamento, lucro, quantidade de funcionários, abrangência geográfica, posicionamento no mercado (como o mercado percebe), etc.;
- Modelo de negócio (tradicional vs. digital);
 - *Tradicional: depende da presença física e de ativos tangíveis (lojas, estoque, equipe local). Alcance limitado + escalar demanda \$\$\$*
 - *Digital: se apoia em tecnologia, dados e plataformas online. Tem alcance global e escala rapidamente (custo marginal baixo)*
- Produtos/serviços oferecidos;
- Principais processos de negócio;
- Tecnologias e sistemas de informação atualmente utilizados pelo negócio;
- Grau de dependência do negócio em relação à tecnologia da informação;
- Problemas que a empresa atualmente enfrenta a respeito de eficiência e/ou eficácia no negócio



Trabalho Final

3. Tecnologias Digitais Propostas

- Quais tecnologias digitais podem resolver os problemas de negócio citados acima? O grupo deve escolher 2-3 tecnologias digitais para adotar na empresa.
- Análise das tecnologias digitais escolhidas para adoção:
 - Descrição da tecnologia e suas aplicabilidades no negócio;
 - Principais vantagens/desvantagens, riscos e benefícios;
 - Alinhamento da tecnologia em relação à missão, visão, valores e objetivos estratégicos da organização;
 - Potenciais vantagens competitivas geradas pela tecnologia;
 - Descrição sobre o uso da tecnologia nos processos de negócio;
 - Impactos nos *stakeholders* e nos processos de negócio por conta da adoção da tecnologia

4. Plano de Ação

- Quais são os prazos adequados para a adoção destas tecnologias digitais na empresa escolhida?
- O Grupo deve propor um cronograma macro apresentando as principais etapas, atividades e prazos para a adoção destas tecnologias.



Trabalho Final

■ Modelo Fictício Sumário Executivo:

Sumário Executivo – Grão Nobre Cafeterias

[A empresa] A Grão Nobre é uma rede de cafeterias com torrefação própria, com 12 lojas na Grande São Paulo, faturamento de R\$ 38 milhões por ano e lucro líquido de R\$ 2,3 milhões (6%). Fundada em 2011, tem 180 funcionários e posicionamento premium acessível, com ticket médio de R\$ 34. O modelo de negócio combina venda nas lojas (78% da receita), venda de grãos a empresas (15%) e e-commerce (7%). A dependência de TI é média: a rede usa ERP local, PDV básico e planilhas, sem integração entre lojas, estoque e clientes.

[Problemas Identificados] As entrevistas com a gerência e a análise dos dados revelaram três problemas de eficiência e eficácia:

- Perdas de estoque: 9% dos insumos perecíveis são descartados, pois a previsão de demanda é feita em planilhas.
- Filas nos horários de pico: esperas de até 12 minutos levam clientes a desistir da compra.
- Falta de dados de clientes: 70% das vendas não são identificadas, o que impede fidelização e promoções direcionadas.



Trabalho Final

[Tecnologia digitais propostas] O grupo propõe três tecnologias que atacam diretamente os problemas acima:

- a) Aplicativo de pedidos e fidelidade com CRM: pedido antecipado e pagamento por Pix reduzem filas e identificam o cliente.
- b) ERP em nuvem integrado a Business Intelligence (BI): unifica vendas e estoque das 12 lojas em tempo real.
- c) Previsão de demanda com Inteligência Artificial: usa histórico de vendas, clima e calendário para definir as compras e a produção diária.

[Vantagens, impactos e riscos] As tecnologias estão alinhadas à visão de ser a cafeteria mais conveniente da cidade e geram vantagem competitiva em dados e experiência do cliente, difícil de copiar por concorrentes menores. As metas para 24 meses são reduzir as perdas de 9% para 5%, elevar o ticket médio em 12% e aumentar a recorrência de clientes em 20%. Baristas e gerentes terão novas rotinas, os clientes ganham conveniência e os fornecedores passam a receber pedidos automáticos. Os principais riscos são a resistência da equipe, a baixa qualidade dos dados históricos, a adequação à LGPD e a dependência de fornecedores de software. Eles serão mitigados com treinamento, projeto-piloto e contratos com nível de serviço (SLA).



Trabalho Final

- **Entregas/Datas do Trabalho Final:**

- 02/10: Informar nome da empresa
- 30/10: Discussão do trabalho final (o que fazer e como)
- 06/11: Entrega parcial (itens 2 e 3 do roteiro: rascunho da caracterização da empresa pesquisada e tecnologias digitais propostas)
- 13/11: Orientação e escrita da versão final do trabalho (ajustes e dúvidas sobre itens 1 e 4 do roteiro → sumário executivo e plano de ação)
- 14/11: Atividade Monitorada (finalização da escrita do relatório)
- 15/11: Data limite para entrega do relatório final



Trabalho Final

[Plano de ação e conclusão] A implantação leva em torno de 18 meses, exige investimento aproximado de R\$ 1,1 milhão e tem retorno (payback) estimado em 22 meses:

- Meses 1 a 2: diagnóstico dos processos, escolha dos fornecedores e formação da equipe do projeto.
- Meses 3 a 5: ERP em nuvem e BI, com piloto em 2 lojas.
- Meses 6 a 9: aplicativo com CRM e expansão do ERP para as 12 lojas.
- Meses 10 a 12: IA de previsão de demanda e avaliação do resultado.

Conclui-se que a digitalização integrada reduz desperdícios, melhora a experiência do cliente e sustenta o crescimento da rede com dados.

Leitura Complementar

Davenport, T. H., & Harris, J. G. (2017). *Competing on analytics: Updated, with a new introduction*. Harvard Business Review Press.

Sharda, R., Delen, D., & Turban, E. (2024). *Business intelligence, analytics, data science, and AI (12th ed.)*. Pearson.

Provost, F., & Fawcett, T. (2013). *Data science for business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media.